Proyecto- Entrega 1: IBM Telco Customer Churn

Estudiantes:

Karen Valencia
Juan Santiago Pacheco
Carlos Andres Amado

Problema abordado y contexto

En el sector de las telecomunicaciones, la permanencia de los clientes es un factor importante para la estabilidad de los ingresos y la sostenibilidad del negocio. Cuando un cliente cancela sus servicios, la empresa pierde los ingresos asociados y puede necesitar invertir recursos para captar nuevos clientes. Sin embargo, no todos los clientes tienen el mismo comportamiento ni las mismas razones para abandonar el servicio. Factores como la antigüedad, el tipo de contrato, los cargos mensuales y los servicios contratados podrían estar relacionados con la decisión de retirarse.

En este contexto, el análisis de datos ofrece una oportunidad para identificar patrones asociados al abandono y evaluar si es posible anticipar qué clientes presentan un mayor riesgo de cancelación. Esta información podría apoyar la toma de decisiones comerciales y la priorización de acciones de retención. El cliente puede cambiar de operador con poca fricción, en especial cuando tiene contrato mes a mes. Adquirir un cliente nuevo puede costar entre 5 y 25 veces más que retener uno actual (Gallo, 2014), por lo que la tasa de cancelación (churn) es uno de los indicadores con mayor impacto en los ingresos y en el valor de una operadora.

La operadora analizada pierde cada mes al 26,5 % de sus clientes, lo que equivale al 30,5 % de su ingreso mensual recurrente (MRR): USD 139 mil al mes, cerca de USD 1,67 millones al año. Hoy el área de retención actúa de forma reactiva, cuando el cliente ya solicitó la cancelación, y con una capacidad de contacto limitada no cuenta con un criterio objetivo para decidir a quién intervenir ni con qué oferta. Los datos muestran que el riesgo se concentra en perfiles identificables (contrato mes a mes, fibra óptica, pago con cheque electrónico y menos de un año de antigüedad): un segmento con el 19 % de los clientes explica el 49 % del MRR perdido. Esto hace viable un enfoque predictivo.

¿Por qué un modelo es útil? Un modelo supervisado de clasificación permite:

1. Estimar la probabilidad de churn de cada cliente antes de que solicite la cancelación.

2. Combinarla con su MRR para obtener la pérdida esperada y priorizar donde más ingreso se protege.

3. identificar los factores que explican el riesgo, de modo que el área elija la palanca de retención adecuada.

Pregunta de negocio y alcance del proyecto

¿Cómo identificar a los clientes con mayor probabilidad de abandonar los servicios de telecomunicaciones, a partir de sus características contractuales, valor del cliente y de consumo, para priorizar posibles acciones de retención?

El proyecto utilizará el conjunto de datos IBM Telco Customer Churn para analizar las características de los clientes y su relación con el abandono del servicio. El trabajo comprenderá la revisión y preparación de los datos, el análisis exploratorio para identificar patrones relevantes y la evaluación de un modelo de clasificación que permita estimar la probabilidad de abandono. También se diseñará un mockup de dashboard para presentar los principales hallazgos y facilitar la interpretación de los resultados.

El análisis se limitará a las variables disponibles en el conjunto de datos. Las recomendaciones de retención serán propuestas analíticas y no se asumirán como estrategias validadas en una operación comercial real. La implementación completa del modelo y sus componentes se desarrollará conforme a las siguientes fases del proyecto académico.

Conjunto de datos a emplear

Para el desarrollo del proyecto se utilizará el conjunto de datos IBM Telco Customer Churn, publicado por IBM como parte de sus datos de ejemplo para analítica. La información corresponde a una empresa ficticia de telecomunicaciones y permite estudiar características de los clientes y su relación con el abandono del servicio.

Link: https://www.kaggle.com/datasets/blastchar/telco-customer-churn/data

Atributo	Detalle
Fuente	Kaggle blastchar/telco-customer-churn (IBM Sample Data Sets), uso público
Archivo	WA_Fn-UseC_-Telco-Customer-Churn.csv (≈ 950 KB)
Tamaño	7.043 clientes × 21 variables (20 predictoras + variable objetivo Churn)
Unidad de análisis	Un cliente; Churn = canceló el servicio en el último mes (Yes/No)
Versionamiento	Datos crudos con dvc add; datos procesados como salidas del pipeline DVC; remoto en AWS S3

Grupo	Variables	Descripción
Demográficas (4)	gender, SeniorCitizen, Partner, Dependents	Perfil del titular
Cuenta (4)	tenure, Contract, PaperlessBilling, PaymentMethod	Antigüedad (meses), tipo de contrato y forma de pago
Servicios (9)	PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies	Servicios contratados
Facturación (2)	MonthlyCharges, TotalCharges	Cargo mensual y acumulado (USD)
Llave / objetivo	customerID / Churn	Identificador único / cancelación

Características generales: El archivo seleccionado está en formato CSV y contiene 7.043 registros de clientes y 21 columnas. Cada registro representa un cliente e incluye información demográfica, características de la cuenta, servicios contratados, condiciones de facturación y estado de abandono.

Las variables se pueden agrupar en las siguientes categorías:

Información del cliente: género, condición de adulto mayor, pareja y dependientes.
Antigüedad y servicios: meses de permanencia, telefonía, líneas múltiples, internet, seguridad, soporte técnico y servicios de entretenimiento.

Contrato y facturación: tipo de contrato, facturación electrónica, método de pago, cargos mensuales y cargos totales.

Variable objetivo: Churn, que indica si el cliente abandonó (Yes) o permaneció (No) en el servicio.

Uso de los datos: La variable Churn se utilizará como referencia para estudiar el abandono y evaluar un modelo de clasificación. Las demás variables se analizarán para identificar cuáles aportan información relevante sobre este comportamiento. El identificador customerID servirá para identificar registros, pero no se utilizará directamente como predictor del modelo.

Limitaciones: La base representa un escenario ficticio y no corresponde a clientes reales ni constituye una muestra representativa del mercado colombiano. Además, contiene información de un periodo específico y no una secuencia histórica de observaciones de cada cliente. Por tanto, los resultados permitirán desarrollar y evaluar una solución académica, pero no demostrarán por sí solos su efectividad en una operación comercial real.

6. Repositorios: Git para el código y DVC para los datos

Git (GitHub): https://github.com/t3indexpg/telco-churn.git Contiene el código del pipeline (src/data), la exploración (notebooks), las figuras (reports), la definición del pipeline (dvc.yaml, params.yaml, dvc.lock) y los metadatos de los datos (*.dvc). Los archivos CSV no se suben a Git.

DVC: los datos crudos se versionan con dvc add (hash MD5) y los procesados como salidas del pipeline de dos etapas: preparar (limpieza y variables derivadas) y particion (train/test estratificado). El almacenamiento remoto es un bucket de AWS S3 (s3://telco-churn-dvc-t3indexpg/dvcstore), sincronizado con dvc push.

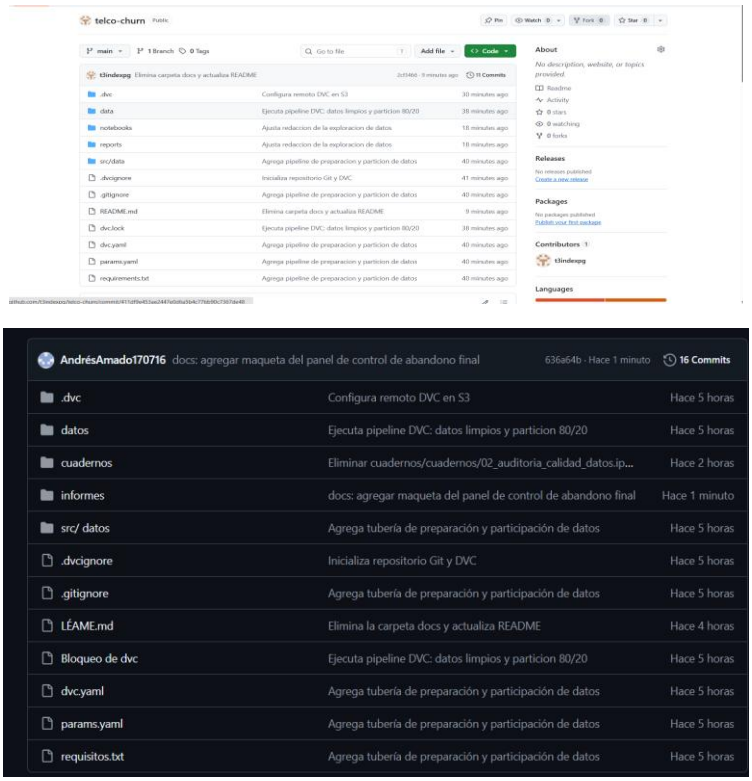


Figura 6. Repositorio en GitHub

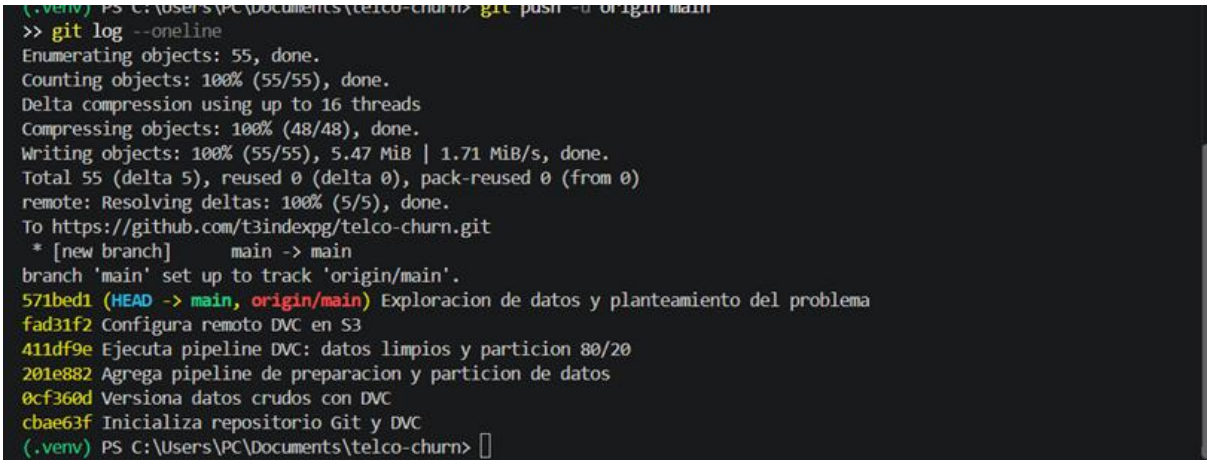


Figura 7. Publicación en el remoto y historial de commits

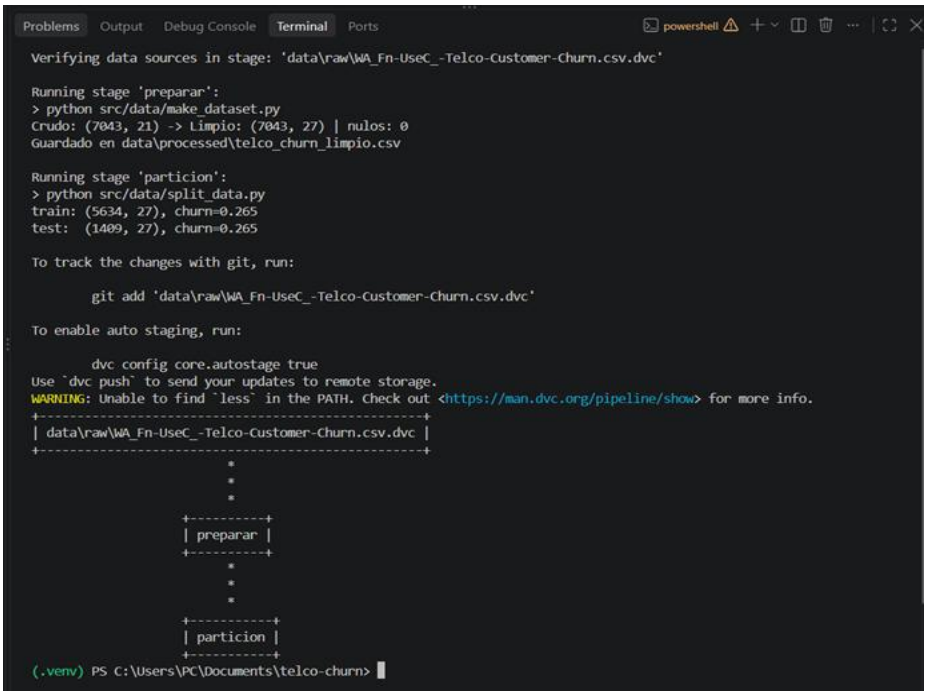


Figura 8. Ejecución del pipeline DVC (dvc repro) y su grafo (dvc dag)



Figura 9. Metadatos DVC del dato crudo: hash MD5 y tamaño



Figura 10. Remoto DVC en S3 sincronizado con la caché local

Referencias

Gallo, A. (2014). The value of keeping the right customers. Harvard Business Review.

IBM / BlastChar (2018). Telco Customer Churn [conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/blastchar/telco-customer-churn

Exploración de datos

La exploración se implementó en notebooks/01_exploracion_datos.ipynb sobre los datos versionados con DVC. La limpieza definida aquí quedó codificada en el pipeline (etapa preparar), de modo que es reproducible con dvc repro.

4.1 Calidad de datos y valores faltantes

- Sin registros ni customerID duplicados, y sin valores atípicos en las variables originales (criterios IQR y $|z| > 3$).
- TotalCharges viene como texto y tiene 11 vacíos ocultos que isna() no detecta. Todos corresponden a clientes con tenure = 0 (aún no facturados) y ninguno hizo churn: es un faltante estructural.
- Se comparó la imputación lógica (TotalCharges = 0) con una imputación multivariada (IterativeImputer ajustado solo con train): la segunda produjo valores negativos de hasta −1.450 USD, sin sentido de negocio. Como TotalCharges ≈ tenure × MonthlyCharges (ρ = 0,9996), se adoptó la imputación con 0.
- Se homologaron categorías redundantes ('No internet service' y 'No phone service' pasan a 'No') y tipos (SeniorCitizen y Churn), y se crearon variables derivadas: tramo de antigüedad, número de servicios, pago automático y variación del cargo mensual.

4.2 Variable objetivo y variables numéricas

El 26,5 % de los clientes hizo churn (razón 2,8 : 1), un desbalance moderado que obliga a usar partición estratificada y métricas centradas en la clase positiva (recall, F1, AUC). Quienes se van tienen una mediana de 10 meses de antigüedad frente a 38 de quienes permanecen, y cargos mensuales más altos (mediana USD 80 vs. 64); las diferencias son significativas (Mann-Whitney, p ≈ 0).

Figura 1. Distribución de tenure, MonthlyCharges y TotalCharges por clase de churn

4.3 ¿Qué se asocia con el churn?

Variable	Mayor riesgo	Menor riesgo
Contrato	Mes a mes: 43 %	1 año: 11 % · 2 años: 3 %
Antigüedad	0-6 meses: 53 %	Más de 48 meses: 10 %
Internet	Fibra óptica: 42 %	DSL: 19 % · Sin internet: 7 %
Medio de pago	Cheque electrónico: 45 %	Pagos automáticos: 15-17 %
Soporte técnico / seguridad online	Sin el servicio: 31 %	Con el servicio: 15 %

Adulto mayor	Sí: 42 %	No: 24 %

La prueba chi² es significativa (p < 0,05) para todas las variables excepto gender y PhoneService, que no aportan y se excluirán del modelo. Por V de Cramér, las asociaciones más fuertes son contrato (0,41), tramo de antigüedad (0,36), tipo de internet (0,32) y medio de pago (0,30). El riesgo es máximo en los primeros meses y decae casi monótonamente: los primeros 12 meses son la ventana crítica de retención.

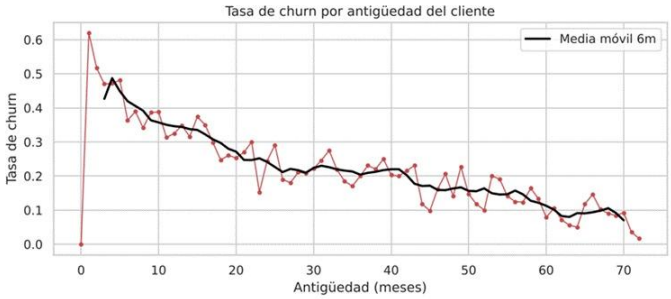


Figura 2. Tasa de churn por antigüedad del cliente

Figura 3. Fuerza de asociación de cada variable con churn (V de Cramér)

4.4 Correlaciones y multicolinealidad

En el correlograma (variables numéricas y categóricas codificadas), las correlaciones positivas con churn más altas corresponden a fibra óptica, cheque electrónico y cargo mensual, y las negativas a antigüedad, contrato de dos años y servicios de protección. Hay multicolinealidad entre tenure y TotalCharges (0,83) y entre MonthlyCharges y número de servicios (0,80); además, el cargo promedio histórico replica a MonthlyCharges (0,996). Estas variables redundantes se excluyen o se controlan en modelos lineales.

4.5 Impacto en el negocio

En la cartera analizada, los clientes que registran abandono representan el 26,5 % del total, pero concentran aproximadamente el 30,5 % de la suma de cargos mensuales. Esto indica que su cargo promedio es mayor que el de quienes permanecen. Al cruzar contrato y servicio de internet, el segmento con contrato mes a mes y fibra óptica presenta una tasa de abandono del 55 % y concentra el 72 % de los cargos mensuales asociados a clientes que abandonaron. Dentro de ese grupo, quienes pagan mediante cheque electrónico (1.307 clientes) presentan una tasa de abandono cercana al 60 % y representan el 49 % de esos cargos. Por ello, se propone priorizar los contactos considerando tanto la probabilidad estimada de abandono como el cargo mensual de cada cliente. Esta priorización es una propuesta analítica: los datos no demuestran todavía que una oferta de retención reduzca el abandono ni cuantifican ingresos efectivamente recuperables.

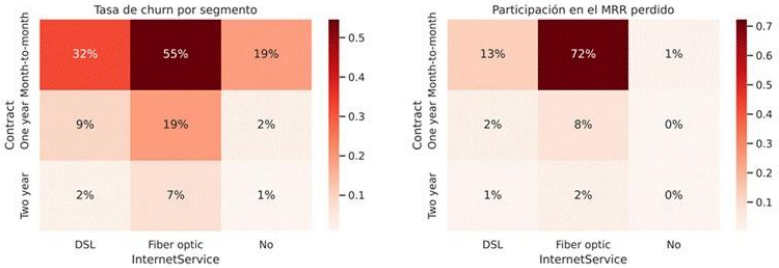


Figura 4. Tasa de churn y participación en el MRR perdido por contrato e internet

4.6 Transformación, desbalance y viabilidad del modelo

Sobre la partición estratificada 80/20 generada por DVC se aplicó one-hot encoding a las variables

nominales y estandarización a las numéricas, ajustadas solo con train. SelectKBest (chi²) confirmó el ranking de variables del análisis bivariado. PCA requiere 14 de 29 componentes para explicar el 90 % de la varianza, por lo que no se usará: no reduce de forma relevante y sacrifica la interpretabilidad que necesita el usuario. Una línea base preliminar valida que el problema es modelable:

Modelo (test, umbral 0,5)	AUC	Recall churn	Precisión	F1
Regresión logística sin balancear	0,842	0,556	0,658	0,603
Regresión logística class_weight	0,842	0,786	0,504	0,614
Regresión logística + SMOTE (train)	0,840	0,797	0,503	0,616
Random Forest + SMOTE (train)	0,838	0,687	0,569	0,622

El balanceo eleva el recall de 56 % a ~79 %, que es lo prioritario para retención (un cliente perdido cuesta más que un contacto innecesario). Contactando solo al 20 % de mayor riesgo se llega al 49 % de los churners y al 54 % del MRR en riesgo (lift 2,5x).

4.7 Hallazgos e implicaciones

• Datos: se identificaron 11 valores vacíos estructurales en TotalCharges, correspondientes a clientes con antigüedad cero; se trataron sin eliminar registros.

• Segmentos: contrato, antigüedad, tipo de internet y medio de pago presentan asociaciones importantes con el abandono. Los clientes con soporte técnico y seguridad en línea registran menores tasas, pero no se puede concluir que contratar esos servicios cause una reducción del riesgo.

• Modelo: las pruebas preliminares de clasificación muestran que es posible ordenar clientes por riesgo. En las siguientes entregas se evaluarán recall, F1, AUC y capacidad de priorización, procurando que las transformaciones y el balanceo se ajusten únicamente con los datos de entrenamiento.

• Uso comercial y prototipo: el tablero combinará filtros descriptivos, ranking por riesgo e ingreso mensual asociado, y un simulador de escenarios. Sus resultados servirán para orientar decisiones, no para garantizar efectos de las ofertas de retención; cualquier estrategia deberá validarse antes de implementarse.

Maqueta (mockup) del prototipo

Objetivo:

Se propone un tablero ejecutivo denominado *IBM Telco Customer Churn: Analítica para la Retención de Clientes*, dirigido a los responsables de retención. Su propósito es integrar el análisis descriptivo del abandono histórico con una propuesta conceptual de priorización de clientes en riesgo, facilitando la identificación de segmentos críticos y apoyando la toma de decisiones.

Diseño del tablero de control



La Figura 1 presenta la maqueta del tablero ejecutivo *IBM Telco Customer Churn: Analítica para la Retención de Clientes*, diseñada para facilitar la comprensión del abandono de clientes y apoyar la identificación de segmentos prioritarios para acciones de retención.

La propuesta se organiza en tres niveles. El primero contiene cinco indicadores clave para ofrecer una

visión general de la cartera y del abandono. El segundo presenta el análisis descriptivo mediante gráficos de tasas de churn por tipo de contrato, método de pago, servicio de internet y antigüedad, además de la distribución de los cargos mensuales. El tercero incorpora una propuesta conceptual de priorización de retención, con niveles de riesgo, análisis del impacto económico, mapa de calor y una tabla de clientes para orientar posibles acciones de contacto.
El diseño contempla filtros por tipo de contrato, método de pago, servicio de internet y antigüedad. Estos elementos se proponen para facilitar el análisis por segmentos y la exploración de patrones de abandono.
La sección predictiva se considera conceptual y sus valores son ilustrativos; no representan resultados validados de un modelo de aprendizaje automático. La implementación posterior deberá conectar los visuales con las fuentes de datos y, cuando esté disponible, con las predicciones de un modelo entrenado y evaluado.
Ubicación prevista de la evidencia: reports/dashboard/mockup_dashboard_churn.png, dentro del repositorio del proyecto en GitHub.
También la ruta directa : https://app.mokkup.ai/shared/88e4f5d9-f483-42ab-82c3-ccef13244a56/join

Reporte trabajo en equipo

Organización y distribución de responsabilidades

El equipo está conformado por Carlos Andrés Amado Cruz, Karen Yulie Valencia Leyva y Juan Santiago Pacheco Gómez. Para esta primera entrega se distribuyeron las actividades de preparación de datos, diseño del prototipo y revisión del documento.

Integrante	Actividades reportadas y contribución
Juan Santiago Pacheco Gómez	Preparación y procesamiento de datos, análisis exploratorio, configuración del repositorio GitHub y versionamiento con DVC. Elaboración de documentación inicial del proyecto.
Carlos Andrés Amado Cruz	Diseño de la maqueta del tablero, organización de indicadores y representación visual de los análisis de abandono de clientes.
Karen Yulie Valencia Leyva	Revisión del enfoque de negocio y propuesta de ajustes en la interpretación de los indicadores de abandono e ingresos; apoyo en la revisión y consolidación del informe.

Coordinación y evidencias

El equipo compartió avances mediante documentos y enlaces de trabajo. El repositorio incluye notebooks, scripts y archivos de configuración de Git/DVC; la maqueta presenta la propuesta de tablero para el usuario final.

Repositorio: https://github.com/t3indexpg/telco-churn

Soportes: informe de la Entrega 1, historial de commits, capturas del pipeline DVC y maqueta del dashboard.

Nota: cada integrante debe validar esta descripción y conservar evidencia de su aporte. Las actividades de revisión propuestas deben reflejar cambios efectivamente realizados.