Proyecto- Entrega 1: IBM Telco Customer Churn

Estudiantes:

Karen Valencia
Juan Santiago Pacheco
Carlos Andres Amado

---

1. Contexto y problema de negocio

El abandono de clientes (Customer Churn) representa un desafío relevante para las empresas de telecomunicaciones, debido a su impacto en la estabilidad de los ingresos, la permanencia de los clientes y la rentabilidad del negocio. Identificar oportunamente a los usuarios con mayor probabilidad de abandonar los servicios permite orientar los esfuerzos comerciales hacia estrategias de retención más focalizadas.

En este proyecto se desarrolla una solución analítica para identificar y priorizar clientes según su riesgo de abandono, utilizando técnicas de Machine Learning aplicadas al conjunto de datos IBM Telco Customer Churn, compuesto por 7.043 registros de clientes y 21 variables originales. La información permite analizar características demográficas, servicios contratados, condiciones de facturación y comportamiento de los clientes.

El propósito no se limita a clasificar a los clientes entre aquellos que abandonan y los que permanecen. También busca proporcionar información que facilite la priorización de las acciones de retención, considerando el riesgo estimado de abandono y el impacto económico asociado a los ingresos recurrentes mensuales (MRR).

1.1 Pregunta de negocio

¿Cómo identificar y priorizar los clientes de una empresa de telecomunicaciones con mayor probabilidad de abandonar sus servicios, considerando su perfil, comportamiento e impacto económico, para orientar de manera más eficiente las estrategias de retención?

1.2 Objetivo de la solución

Desarrollar una solución analítica basada en modelos de Machine Learning que permita estimar la probabilidad de abandono de los clientes, comparar diferentes alternativas de modelamiento y presentar los resultados mediante un tablero de visualización que facilite la identificación de segmentos prioritarios y oportunidades de intervención comercial.

1.3 Preparación y reproducibilidad

El script src/data/make_dataset.py realiza el proceso de preparación de los datos: estandariza los textos, elimina registros duplicados, convierte la variable TotalCharges a formato numérico e imputa con cero los cargos faltantes correspondientes a clientes con antigüedad igual a cero. Además, homogeneiza las categorías de los servicios y crea seis variables derivadas. La ejecución verificada produjo un conjunto de 7.043 registros y 27 columnas, sin valores nulos. El archivo original se almacena en `data/raw` y el conjunto procesado se genera en data/processed. Las instrucciones de ejecución están documentadas en README_DASHBOARD.md.

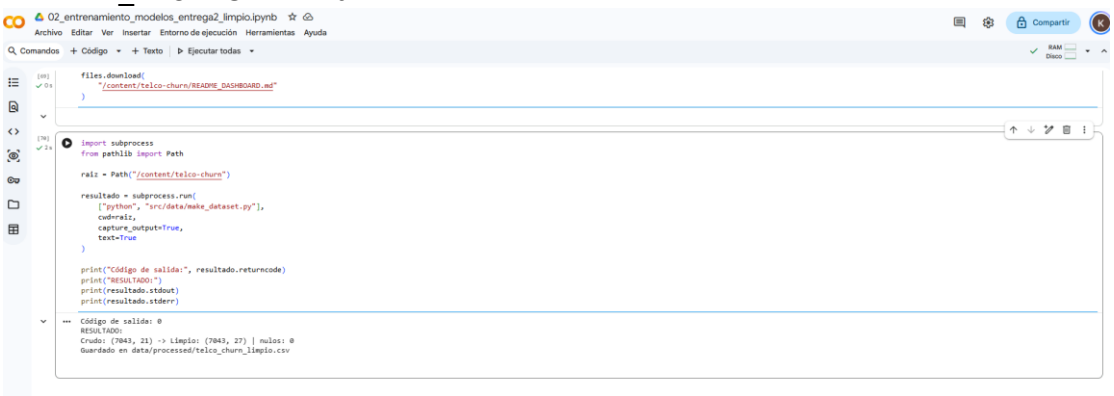


Figura 1. Ejecución reproducible del procesamiento de datos en Colab.

3. Modelos desarrollados y evaluación

Se separaron los datos en entrenamiento (5.634 clientes, 80 %) y prueba (1.409 clientes, 20 %), conservando aproximadamente la proporción de churn (26,5 %). Se excluyeron customerID y Churn de las variables predictoras; las variables numéricas se imputaron y estandarizaron y las categóricas se codificaron. SMOTE se aplicó exclusivamente al entrenamiento en los modelos correspondientes, evitando modificar la distribución del conjunto de prueba.

Se compararon cuatro enfoques de clasificación. Los resultados siguientes corresponden al conjunto de prueba:

Modelo	Accuracy	Precisión	Recall	F1	AUC-ROC
Logística base	0,7984	0,6562	0,5053	0,5710	0,8448
Logística balanceada	0,7388	0,5050	0,8048	0,6206	0,8450
Logística + SMOTE	0,7438	0,5111	0,7995	0,6236	0,8433
Random Forest + SMOTE	0,7757	0,5801	0,5615	0,5707	0,8248

Selección del modelo

Seleccionamos regresión logística balanceada para el prototipo porque obtuvo el mayor recall (0,8048) y el mayor AUC-ROC (0,8450). Dado que el propósito es identificar posibles abandonos, preferimos recuperar una mayor proporción de clientes que realmente abandonan, aunque ello incremente los falsos positivos. La regresión logística con SMOTE obtuvo el mejor F1 (0,6236), por lo que sigue siendo una alternativa competitiva. La selección

es una decisión de negocio sobre el costo relativo de no detectar un abandono; no significa que un modelo sea superior en todas las métricas.

Interpretación de resultados desde la perspectiva del negocio

La regresión logística balanceada permite identificar aproximadamente el 80,5 % de los clientes que efectivamente abandonan el servicio (recall de 0,8048). Este resultado favorece una estrategia de retención orientada a reducir la cantidad de abandonos que pasan inadvertidos. Sin embargo, su precisión de 0,5050 indica que cerca de la mitad de los clientes clasificados como posibles desertores no presentan abandono real, por lo que las acciones comerciales deben priorizarse cuidadosamente.

Desde la perspectiva de rentabilidad, el uso conjunto de la probabilidad estimada de abandono y del ingreso recurrente mensual (MRR) permite identificar clientes que combinan mayor riesgo y mayor impacto económico potencial. Así, la priorización no depende exclusivamente de la probabilidad de churn, sino también del valor económico asociado al cliente.

En consecuencia, el modelo debe entenderse como una herramienta de apoyo a la decisión comercial y no como una confirmación de abandono. Su aplicación debe complementarse con criterios de rentabilidad, costos de retención, capacidad operativa y efectividad de las ofertas comerciales.

Limitaciones de la evaluación

Los indicadores se calcularon sobre una única partición de prueba. No se dispone de evidencia de validación temporal, calibración de probabilidades, costos de intervención o pruebas con usuarios de negocio. Por ello, los umbrales de riesgo del tablero son orientativos y requieren validación posterior.

4. Registro de experimentos en MLflow

Se configuró MLflow 3.18.0 en una máquina virtual AWS EC2, utilizando una base de datos SQLite y almacenamiento de artefactos persistente en la instancia. En el experimento Telco_Churn_Entrega2 se registraron cuatro ejecuciones con métricas comparables. La interfaz se consultó mediante un túnel SSH hacia el puerto 5000, sin exponer públicamente el servicio.

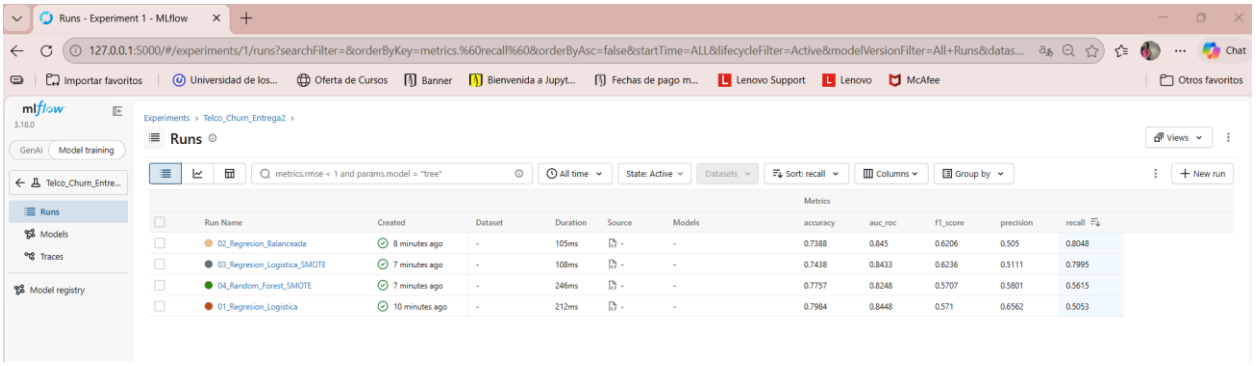


Figura 2. Cuatro ejecuciones y métricas comparativas en MLflow.

El modelo seleccionado se almacenó como artefacto modelo/regresion_balanceada.joblib

dentro de su ejecución. Esta evidencia acredita conservación del archivo, pero no un registro en MLflow Model Registry.

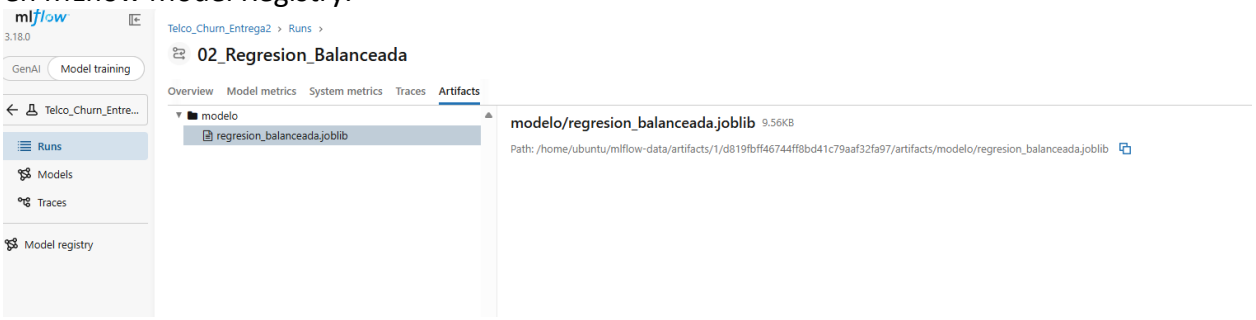


Figura 3. Artefacto joblib de la regresión logística balanceada.

5. Infraestructura AWS EC2

La instancia MIAD-Taller6-APIs (tipo t3.small) se utilizó para alojar el servidor de seguimiento de MLflow. La captura muestra la instancia en ejecución y su dirección IPv4 pública 100.62.107.184. El servidor se ejecutó sobre la interfaz local 127.0.0.1:5000 y se consultó desde el equipo de trabajo mediante redirección de puertos SSH.

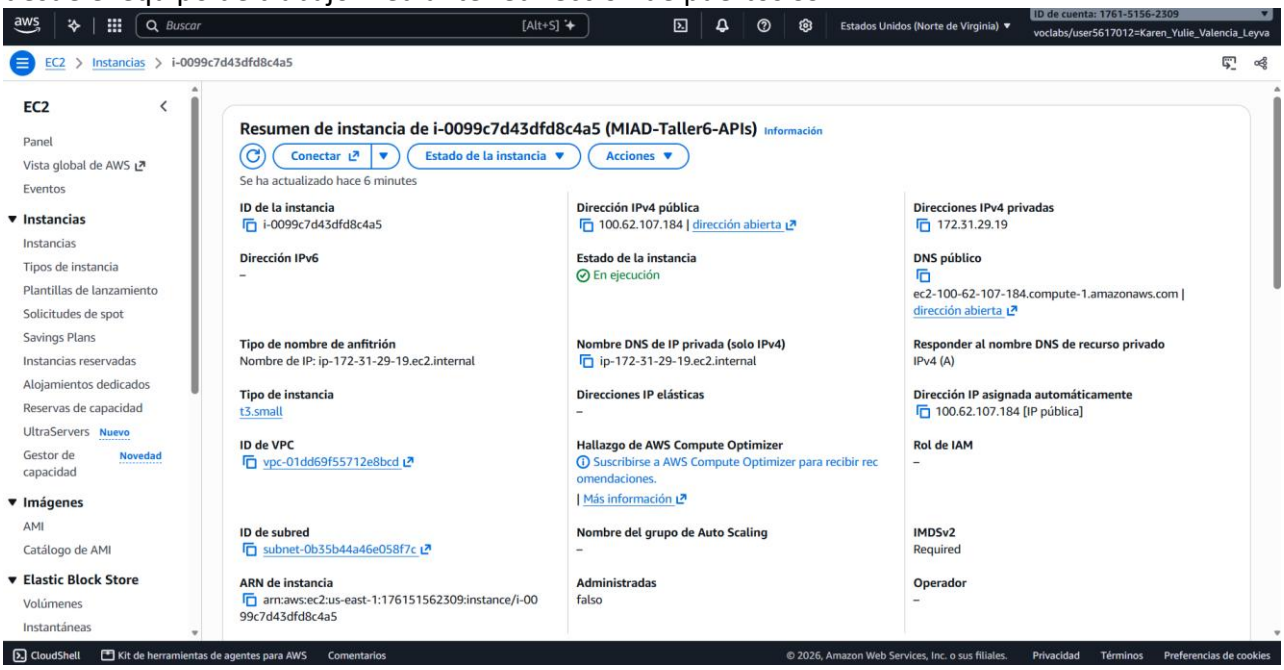


Figura 4. Resumen de instancia EC2, identificador, IP y estado.

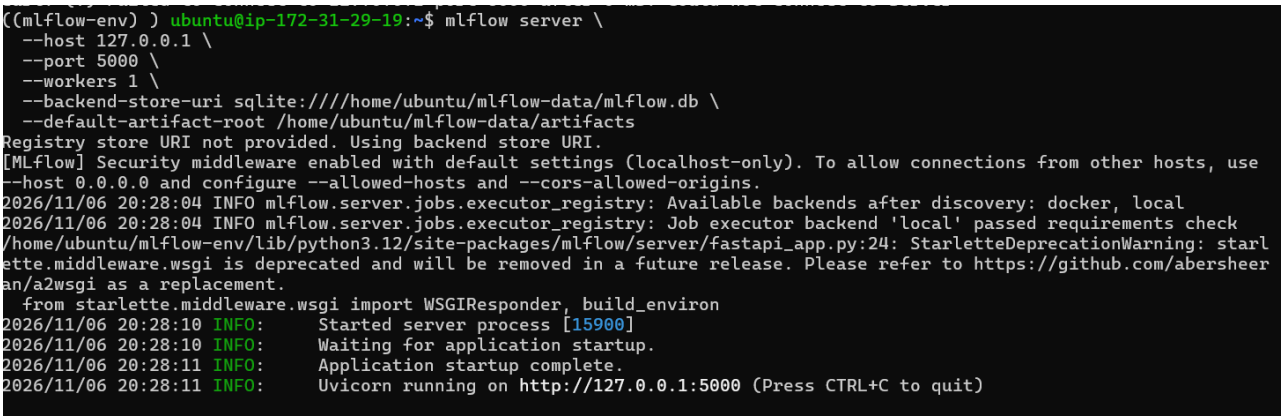


Figura 5. Inicio del servidor MLflow en Ubuntu, puerto local 5000.

→ la guía pide que sean visibles el usuario y la IP de la máquina en EC2, además de la IP asociada a MLflow. Las capturas anteriores documentan el usuario ubuntu, la IP pública de EC2 y el enlace local de MLflow a través del túnel SSH. Al terminar la entrega, la instancia debe detenerse, no terminarse.

6. Dashboard interactivo: análisis histórico

Se implementó un prototipo en Streamlit con filtros por tipo de contrato, método de pago, servicio de internet y antigüedad. La vista histórica utiliza el conjunto completo de 7.043 clientes e incluye número de clientes, abandonos observados, tasa de churn, cargo mensual promedio y MRR histórico asociado a clientes que abandonaron. También permite comparar el abandono por contrato, medio de pago y servicio de internet.

Tablero: https://telco-churn-entrega2.streamlit.app/



Figura 6. Vista general del dashboard con filtro de contratos mensuales.

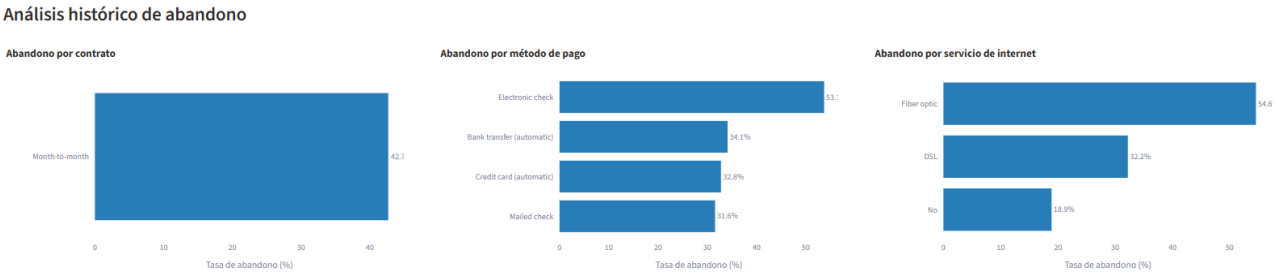


Figura 7. Análisis histórico de abandono por características del cliente.

En el ejemplo filtrado a contratos mes a mes se observan 3.875 clientes, 1.655 abandonos y una tasa histórica de 42,7 %. Estos resultados corresponden únicamente al segmento seleccionado, no a la población completa.

7. Dashboard: predicción y priorización

La vista predictiva utiliza 1.409 registros del conjunto de prueba con probabilidades calculadas previamente mediante la regresión logística balanceada. Los filtros se aplican también a esta muestra. Para el segmento de contratos mensuales aparecen 773 clientes: 346 con riesgo alto, 292 con riesgo medio y 135 con riesgo bajo. El MRR esperado en riesgo se calcula como probabilidad de abandono multiplicada por cargo mensual; es una estimación y no una pérdida confirmada.

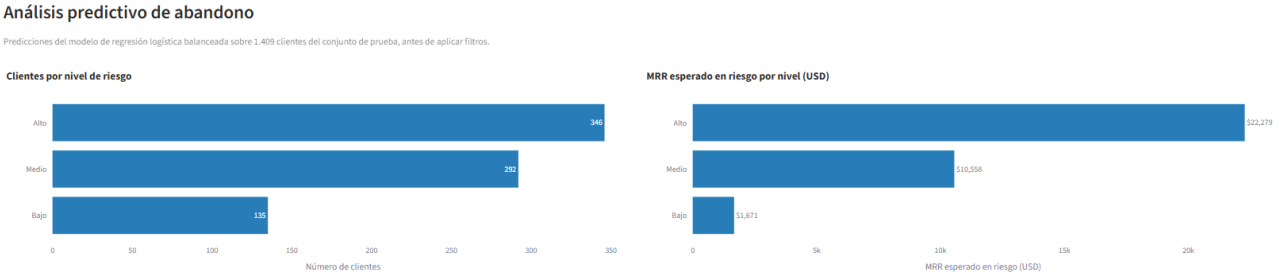


Figura 8. Distribución de clientes y MRR esperado en riesgo.

La matriz combina el nivel de riesgo con el impacto económico, clasificado mediante percentiles 33 y 67 del cargo mensual del conjunto de prueba. La tabla final ordena clientes según su MRR esperado en riesgo e incorpora la opción de descargar el listado en CSV.

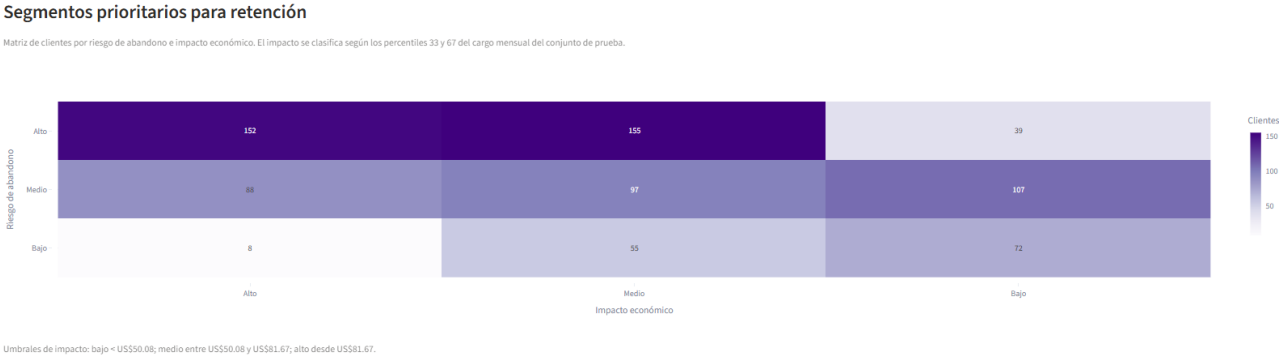


Figura 9. Matriz de riesgo de abandono e impacto económico.

8. Decisión comercial y límites del prototipo

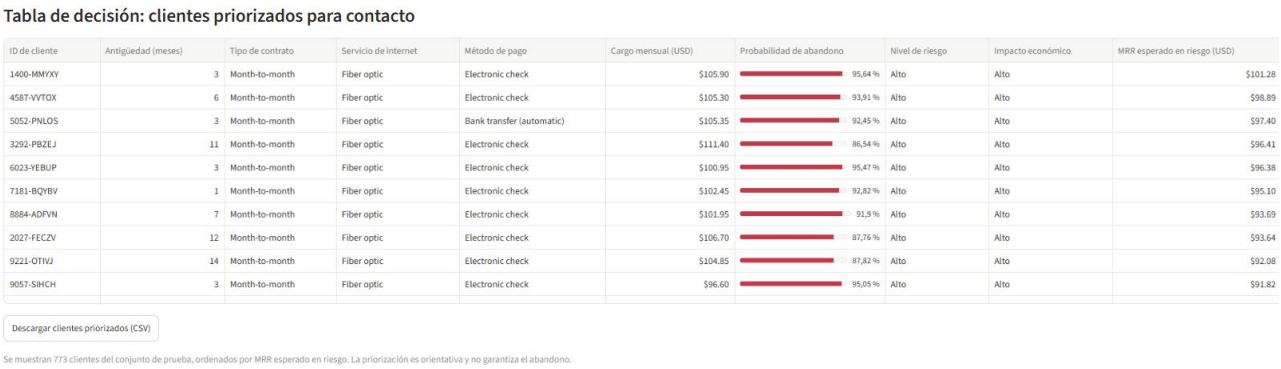


Figura 10. Tabla de clientes priorizados y descarga CSV.

La tabla permite orientar una primera lista de contactos para retención, pero la priorización debe contrastarse con presupuesto, efectividad esperada de las ofertas, capacidad operativa y consentimiento para contacto. El dashboard actualmente lee un CSV de predicciones ya generadas; no solicita nuevas inferencias a una API. Tampoco se ha probado en un entorno productivo ni se ha validado la estabilidad del modelo frente a cambios de comportamiento.

Criterios para la priorización comercial

Desde una perspectiva de gestión de ingresos, la priorización de clientes debe combinar dos dimensiones: la probabilidad estimada de abandono y el MRR potencialmente expuesto. Los clientes con mayor riesgo y mayor contribución económica pueden constituir el primer grupo de atención, mientras que aquellos con menor impacto económico pueden gestionarse mediante estrategias de retención de menor costo o acciones automatizadas.

Esta segmentación permite orientar los recursos comerciales hacia oportunidades de intervención con mayor relevancia económica. Sin embargo, antes de ejecutar campañas, es necesario evaluar el costo de los incentivos, el margen de contribución del cliente, la probabilidad de éxito de la acción y el costo de contacto. De esta manera, la decisión no se limita a retener el mayor número de clientes, sino a buscar una relación favorable entre el ingreso que se espera proteger y el costo de la intervención.

El prototipo representa una primera aproximación a este esquema de decisión. No constituye todavía un modelo de optimización de rentabilidad ni demuestra el efecto causal de las acciones de retención sobre la permanencia de los clientes.

Reproducibilidad del tablero

El código de la aplicación está en app.py, las dependencias en requirements.txt y las instrucciones en README_DASHBOARD.md. El dataset histórico debe generarse desde el CSV crudo con python src/data/make_dataset.py. El archivo reports/dashboard/predicciones_churn.csv contiene las probabilidades para la muestra de prueba. Desde la raíz del repositorio, la aplicación se ejecuta con streamlit run app.py.

9. Repositorio y trazabilidad de aportes

Repositorio: https://github.com/t3indexpg/telco-churn. **La rama feature/entrega2** contiene

commits verificables relacionados con el dashboard, dependencias, datos predictivos, documentación y materiales del entrenamiento.

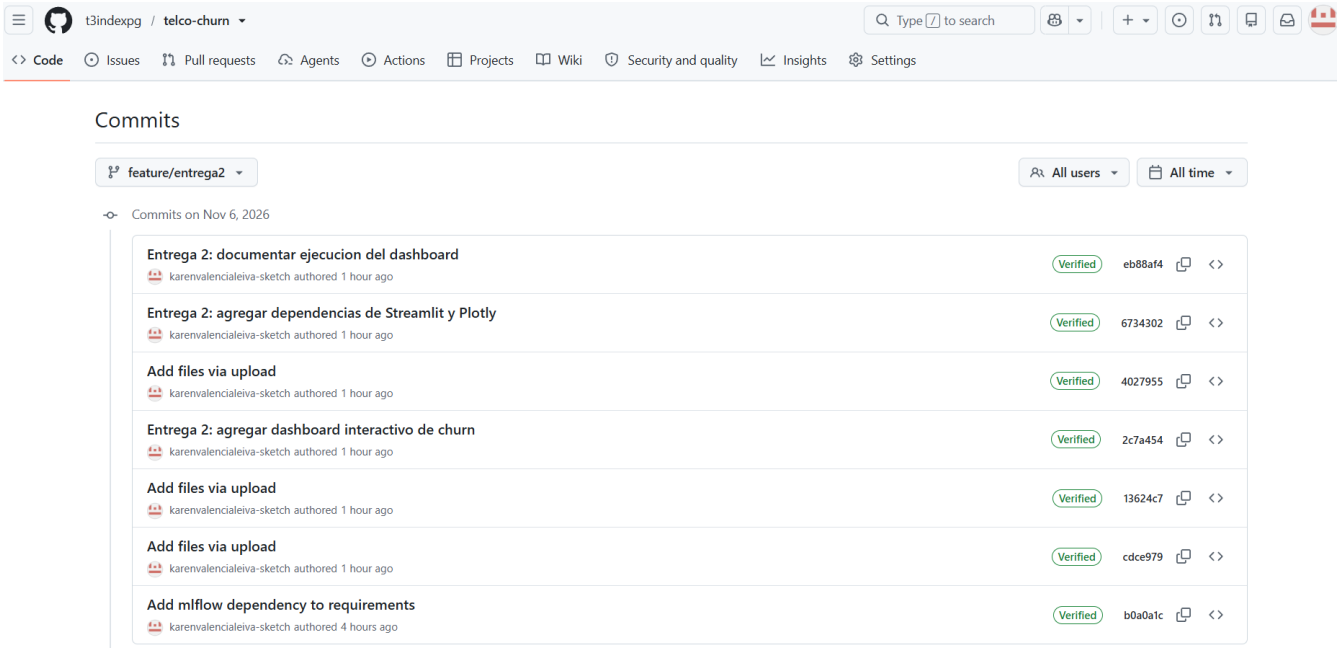


Figura 11. Historial de commits en la rama de trabajo de Karen.

Cierre de infraestructura AWS. Tras completar las pruebas y registrar los experimentos y artefactos en MLflow, se detuvo la instancia EC2 MIAD-Taller6-APIs (i-0099c7d43dfd8c4a5), sin terminarla. La consola AWS muestra el estado «Detenida», conforme a la indicación de la guía.

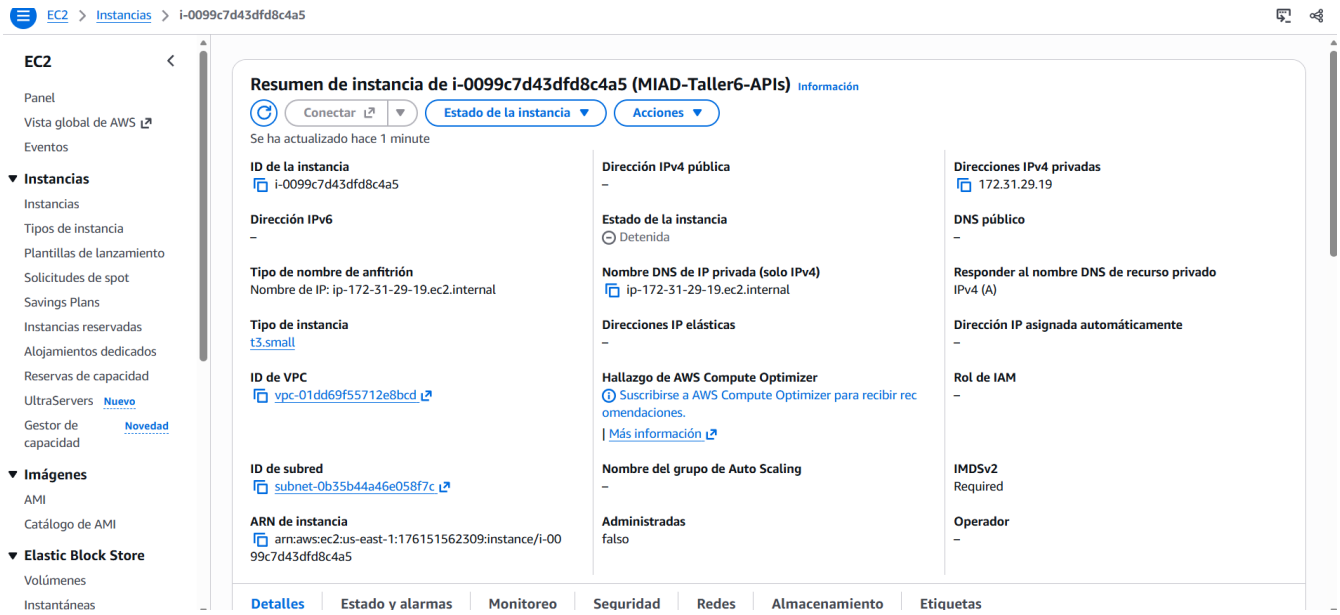


Figura 12. Estado final «Detenida» de la instancia EC2 en AWS.

10. Conclusiones y próximos pasos

La segunda entrega permitió pasar del planteamiento del problema y la maqueta a un prototipo funcional que compara modelos supervisados y presenta resultados interpretables para apoyar decisiones de retención. La regresión logística balanceada resultó adecuada para priorizar cobertura de posibles abandonos, con recall de 0,8048, aunque con precisión de 0,5050. La comparación evidencia que no existe una elección única independiente del objetivo de negocio.

El registro de métricas y artefactos en MLflow facilita rastrear los experimentos. El dashboard permite explorar segmentos, cuantificar el riesgo esperado y descargar una lista orientativa de clientes priorizados. La limpieza de datos se reprodujo correctamente, con 7.043 registros, 27 variables y sin valores faltantes.

Como siguientes pasos se propone validar la calibración de las probabilidades y los umbrales de riesgo, estimar el valor económico de intervenciones, empaquetar el modelo, construir una API de inferencia, conectar el tablero a dicha API y desplegar los componentes mediante Docker, de acuerdo con el alcance general del curso.

Reporte de trabajo en equipo

El equipo está conformado por Carlos Andrés Amado Cruz, Karen Yulie Valencia Leyva y Juan Santiago Pacheco Gómez. El desarrollo de la segunda entrega se realizó mediante un trabajo colaborativo, en el que cada integrante aportó desde sus fortalezas y responsabilidades, contribuyendo a la construcción y consolidación de la solución analítica.

- **Juan Santiago Pacheco Gómez:** contribuyó al componente de preparación y estructuración de los datos, exploración de la información y fortalecimiento de la reproducibilidad del proyecto. Sus aportes permitieron disponer de una base consistente para el desarrollo y evaluación de los modelos analíticos.

- **Karen Yulie Valencia Leyva:** lideró una parte fundamental del desarrollo técnico de la segunda entrega, con participación destacada en la construcción y evaluación de los modelos de clasificación, la experimentación y seguimiento mediante MLflow, así como en el desarrollo del tablero analítico. También contribuyó a integrar los resultados técnicos en una solución orientada a la identificación y priorización de clientes con riesgo de abandono.

- **Carlos Andrés Amado Cruz:** aportó a la orientación del proyecto desde la perspectiva de negocio, la definición y organización de indicadores, la estructuración de la propuesta de visualización y la interpretación de los resultados desde su impacto comercial y financiero. Asimismo, contribuyó al fortalecimiento del informe, particularmente en la contextualización del problema, la interpretación de los modelos y los criterios de priorización comercial.

La articulación de estos aportes permitió integrar la preparación de datos, el desarrollo técnico, la visualización y la interpretación de negocio en una solución analítica común. Las contribuciones individuales se complementan con la trazabilidad de los cambios y entregables disponibles en el repositorio del proyecto.